

YOLO 物件偵測圖表閱讀教學： 資料分布、訓練曲線與混淆矩陣

1 前言：這三張圖的目的

本文件示範如何閱讀 YOLO 物件偵測訓練結果中的三類圖表：

1. **資料集標註分布圖**：確認類別數量是否平衡、標註框位置是否集中、物件大小是否偏小。
2. **訓練與驗證曲線圖**：判斷模型是否收斂、是否過擬合、precision、recall、mAP 是否穩定。
3. **混淆矩陣**：找出模型最容易誤判的類別，以及誤檢與漏檢問題。

閱讀物件偵測結果時的重點

物件偵測不是只看 accuracy。因為模型同時要完成兩件事：

分類正確 + 框的位置正確

所以常用指標包含：

Precision, Recall, IoU, AP, mAP@50, mAP@50:95

2 圖一：資料集與標註分布圖




Figure 1: 資料集標註數量、標註框位置與標註框大小分布

2.1 左上圖：各類別 instances 數量

左上圖顯示不同類別的標註框數量。這裡的 **instances** 指的是標註框數量，而不是圖片張數。若一張圖片中有 5 個安全帽標註框，則 helmet 的 instances 會增加 5。

Table 1: 各類別標註框數量

類別	instances 數量
helmet	25,916
vest	20,595
no-helmet	8,536
no-vest	19,742
worker	7,610
head	25,249

2.1.1 數學上怎麼算？

假設資料集中共有 N 個標註框，第 i 個標註框的類別為 y_i ，類別集合為 $\mathcal{C}$ 。某一類別 c 的標註數量可表示為：

$$N_c = \sum_{i=1}^N \mathbf{1}(y_i = c)$$

其中 $\mathbf{1}(\cdot)$ 是 indicator function，條件成立時為 1，不成立時為 0。
例如 helmet 的標註數量是：

$$N_{helmet} = 25,916$$

worker 的標註數量是：

$$N_{worker} = 7,610$$

因此最大類別與最小類別的數量比例為：

$$\text{Imbalance Ratio} = \frac{\max_{c \in \mathcal{C}} N_c}{\min_{c \in \mathcal{C}} N_c} = \frac{25,916}{7,610} \approx 3.41$$

這代表最多類別的標註數大約是最少類別的 3.41 倍。

專業術語：Class Imbalance 類別不平衡

Class imbalance 是指不同類別的資料量差距明顯。當某些類別資料量較少時，模型在訓練時看到該類的機會較低，因此可能導致該類別 recall 偏低、容易漏檢或容易被其他類別取代。

2.2 右上圖：所有 Bounding Box 疊圖

右上圖將所有 bounding box 疊在同一張圖中，用來觀察標註框形狀與大小的整體分布。圖中大多數框呈現垂直長方形，代表資料集中許多物件是人、頭、安全帽、背心等直立型目標。

2.2.1 YOLO 標註格式與座標轉換

YOLO 常用的標註格式為：

$$(c_x, c_y, w, h)$$

其中：

- c_x ：bounding box 中心點的水平座標。
- c_y ：bounding box 中心點的垂直座標。
- w ：bounding box 寬度。
- h ：bounding box 高度。

這些數值通常都是正規化後的座標，範圍介於 0 到 1。

若原始圖片寬度為 W ，高度為 H ，則正規化座標轉回像素座標的公式為：

$$x_{min} = \left(c_x - \frac{w}{2}\right) W$$

$$x_{max} = \left(c_x + \frac{w}{2}\right) W$$

$$y_{min} = \left(c_y - \frac{h}{2}\right) H$$

$$y_{max} = \left(c_y + \frac{h}{2}\right) H$$

若要從像素座標轉回 YOLO 格式，公式為：

$$c_x = \frac{x_{min} + x_{max}}{2W}, \quad c_y = \frac{y_{min} + y_{max}}{2H}$$

$$w = \frac{x_{max} - x_{min}}{W}, \quad h = \frac{y_{max} - y_{min}}{H}$$

專業術語：Bounding Box 邊界框

Bounding box 是物件偵測中標示物件位置的矩形框。模型不只要判斷物件類別，也要預測該物件的座標位置。

2.3 左下圖：標註框中心點 x, y 分布

左下圖是標註框中心點的二維分布圖。顏色越深，表示該區域出現越多物件中心點。

這張圖可以看出：

- 標註框中心點大量集中在畫面中下方。
- y 約在 0.05 到 0.3 的區域特別密集。
- 上半部區域較少出現物件。

這代表訓練資料的拍攝角度或場景可能有固定模式。若未來測試場景的物件常出現在畫面上方，模型可能會較容易漏檢。

2.3.1 二維直方圖怎麼算？

假設每個標註框中心點為 (x_i, y_i) 。將 x 軸切成若干區間 B_a^x ，將 y 軸切成若干區間 B_b^y 。第 (a, b) 個格子的數量為：

$$H_{a,b} = \sum_{i=1}^N \mathbf{1}(x_i \in B_a^x, y_i \in B_b^y)$$

其中 $H_{a,b}$ 越大，該區域顏色越深。這就是圖中熱區的來源。

2.4 右下圖：標註框 width 與 height 分布

右下圖顯示標註框寬度 w 與高度 h 的分布。可以看到大部分框都集中在左下角，表示物件在圖片中占比偏小。

2.4.1 物件面積比例怎麼算？

若 bounding box 的正規化寬度與高度分別為 w 與 h ，則該物件在圖片中的面積比例為：

$$A_{box} = w \times h$$

例如若某物件的 $w = 0.08$ ， $h = 0.12$ ，則其面積比例為：

$$A_{box} = 0.08 \times 0.12 = 0.0096$$

也就是該物件只佔整張圖片約：

$$0.0096 \times 100\% = 0.96\%$$

這類物件屬於小物件，通常比大物件更難偵測。

專業術語：Small Object Detection 小物件偵測

小物件偵測是指目標物在整張圖片中占比很小。小物件的像素資訊少，特徵不明顯，因此容易造成漏檢、分類錯誤或定位不準。

圖一結論

資料集標註數量充足，但類別分布不完全平均，最大類別與最小類別約有 3.41 倍差距。此外，標註框中心點集中於畫面中下方，且許多物件偏小。因此後續模型的主要挑戰會是：小物件偵測、類別不平衡，以及特定視角資料分布造成的泛化問題。

3 圖二：訓練曲線與模型收斂判斷




Figure 2: YOLO 訓練與驗證曲線

3.1 Loss 的組成

YOLO 類模型的總損失通常可概念化寫成：

$$\mathcal{L}_{total} = \lambda_{box}\mathcal{L}_{box} + \lambda_{cls}\mathcal{L}_{cls} + \lambda_{dfl}\mathcal{L}_{dfl}$$

其中：

- $\mathcal{L}_{box}$ ：邊界框定位損失，用來衡量框的位置是否準確。
- $\mathcal{L}_{cls}$ ：分類損失，用來衡量類別是否判對。
- $\mathcal{L}_{dfl}$ ：Distribution Focal Loss，用來提升邊界框位置回歸的精細度。
- $\lambda_{box}, \lambda_{cls}, \lambda_{dfl}$ ：不同 loss 的權重。

注意

不同 YOLO 版本與實作細節可能會使用不同的 box loss 或分類 loss。這裡的公式是用來教學理解整體概念；實際數值以訓練框架輸出的結果為準。

3.2 Box Loss 與 IoU

Bounding box 定位能力通常與 IoU 有關。IoU 的定義為：

$$\text{IoU} = \frac{|B_{pred} \cap B_{gt}|}{|B_{pred} \cup B_{gt}|}$$

其中：

- B_{pred} ：模型預測框。
- B_{gt} ：人工標註的真實框。
- $B_{pred} \cap B_{gt}$ ：兩個框的交集面積。
- $B_{pred} \cup B_{gt}$ ：兩個框的聯集面積。

概念上，box loss 可以理解成：

$$\mathcal{L}_{box} \propto 1 - \text{IoU}$$

當預測框與真實框越重疊，IoU 越高，box loss 越低。

3.2.1 IoU 計算範例

假設預測框與真實框的交集面積為 80，聯集面積為 120，則：

$$\text{IoU} = \frac{80}{120} = 0.667$$

如果使用簡化概念 $1 - \text{IoU}$ ，則：

$$\mathcal{L}_{box} \approx 1 - 0.667 = 0.333$$

3.3 Classification Loss

分類損失衡量模型是否把物件分到正確類別。若以二元交叉熵作為概念說明，公式為：

$$\mathcal{L}_{cls} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)]$$

其中：

- y_i ：真實標籤。
- $\hat{p}_i$ ：模型預測為該類別的機率。
- N ：樣本數。

如果模型對正確類別的預測機率越高，classification loss 就越低。

3.4 DFL：Distribution Focal Loss

DFL 用來讓模型更細緻地學習 bounding box 邊界位置。它不是只把邊界位置視為單一數值，而是把位置看成一個分布。

概念上，若真實邊界位置落在兩個相鄰離散格 y_l 與 y_r 之間，則 DFL 可寫為：

$$\mathcal{L}_{dfl} = -[(y_r - y) \log(P_l) + (y - y_l) \log(P_r)]$$

其中：

- y ：真實連續位置。
- y_l 、 y_r ：左右相鄰的離散位置。
- P_l 、 P_r ：模型預測落在左右位置的機率。

3.5 這張圖的 Loss 怎麼看？

從訓練曲線中可以觀察到：

- train/box_loss 從約 1.95 降到約 1.65。
- train/cls_loss 從約 2.8 降到約 1.05。
- train/dfl_loss 從約 0.0067 降到約 0.0054。
- val/box_loss 從約 1.62 降到約 1.36。
- val/cls_loss 從約 2.0 降到約 0.92。
- val/dfl_loss 從約 0.0078 降到約 0.0062。

訓練集與驗證集 loss 都下降，代表模型確實有學到有效特徵。驗證 loss 沒有在後期明顯反彈，代表沒有看到嚴重過擬合。

3.6 Precision 與 Recall 的計算

Precision 與 Recall 是物件偵測中非常重要的兩個指標。

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

其中：

- TP ：True Positive，正確偵測到的物件。
- FP ：False Positive，誤檢；模型說有，但實際沒有。
- FN ：False Negative，漏檢；實際有，但模型沒有抓到。

從圖二可看出整體：

$$\text{Precision} \approx 0.84$$

$$\text{Recall} \approx 0.75$$

這代表模型誤報控制尚可，但仍有一定比例的真实物件被漏掉。

3.6.1 F1-score

F1-score 是 precision 與 recall 的調和平均：

$$F_1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

若以圖中最後的整體指標估算，precision 約 0.84，recall 約 0.75，則：

$$F_1 = \frac{2 \times 0.84 \times 0.75}{0.84 + 0.75} = \frac{1.26}{1.59} \approx 0.792$$

所以整體 F1-score 約為 0.79。

3.7 AP、mAP50 與 mAP50-95 的計算

AP 是 Average Precision，代表某一類別在 precision-recall curve 下的面積：

$$AP_c = \int_0^1 P_c(R) dR$$

在實作上通常用離散近似：

$$AP_c \approx \sum_n (R_n - R_{n-1}) P_{interp}(R_n)$$

其中：

- $P_c(R)$ ：類別 c 在不同 recall 下的 precision。
- R_n ：第 n 個 recall 門檻。

- P_{interp} ：插值後的 precision。

mAP 是所有類別 AP 的平均：

$$mAP = \frac{1}{|\mathcal{C}|} \sum_{c \in \mathcal{C}} AP_c$$

mAP50 表示 IoU 門檻固定為 0.5：

$$mAP@50 = \frac{1}{|\mathcal{C}|} \sum_{c \in \mathcal{C}} AP_c^{IoU=0.50}$$

mAP50-95 則是從 IoU 0.50 到 0.95，每 0.05 計算一次 AP 後取平均：

$$mAP@50:95 = \frac{1}{10} \sum_{t \in \{0.50, 0.55, \dots, 0.95\}} mAP@t$$

mAP 不能只靠單一混淆矩陣算出

mAP 需要模型在不同 confidence threshold 下形成 precision-recall curve，所以不能只用單一固定閾值的混淆矩陣完整計算。混淆矩陣可以幫助分析錯誤類型，但 mAP 需要完整的預測分數與 IoU 匹配結果。

3.8 圖二的整體判讀

圖二顯示：

- loss 持續下降，模型有學到東西。
- validation loss 沒有明顯上升，因此沒有嚴重過擬合。
- precision 約 0.84，表示模型偵測出的物件多數是正確的。
- recall 約 0.75，表示仍存在漏檢。
- mAP50 約 0.84，表示一般偵測能力不錯。
- mAP50-95 約 0.52，表示嚴格定位能力仍需改善。

圖二結論

這個模型可以判定為基本收斂 (有收斂傾向，並非結果收斂。)。它不是訓練失敗，因為 loss 有下降且 mAP 有上升。不過 mAP50-95 與 recall 仍有改善空間，代表模型在小物件、邊界框定位、漏檢控制方面還可以繼續加強。

3.9 如何判斷模型是否收斂 (Convergence Analysis)

在深度學習中，模型是否收斂 (Convergence) 不能僅依靠單一指標判斷，而應綜合觀察 Loss、Precision、Recall 以及 mAP 等多項指標。

一般而言，可依照以下四個步驟進行判斷。

3.9.1 (1) Loss 是否逐漸下降

首先觀察訓練集 (Training Loss) 與驗證集 (Validation Loss)。

若模型正常學習，應滿足

$$L_{t+1} < L_t$$

其中

$$L_t$$

表示第 t 個 epoch 的 loss。

若後期變成

$$L_{t+1} \approx L_t$$

代表 loss 已經趨於穩定。

換句話說，

$$\lim_{t \rightarrow \infty} (L_{t+1} - L_t) = 0$$

代表模型參數更新幅度已非常小，通常表示模型已接近收斂。

本研究中可以觀察到：

- train box loss 持續下降
- train cls loss 持續下降
- val box loss 持續下降
- val cls loss 持續下降
- val dfl loss 持續下降

因此 Loss 呈現典型收斂現象。

3.9.2 (2) 曲線最後是否趨於水平？

很多人會直接觀察曲線最後是否變平。

這是一種快速判斷方式，但不能單獨作為收斂依據。

若曲線最後滿足

$$\frac{dL}{dt} \approx 0$$

代表 Loss 的下降速度已趨近於零，亦即模型更新已逐漸停止。

因此曲線若由快速下降轉為近似水平，通常表示模型已進入收斂區域。

然而，仍需搭配 Validation Loss、Precision 與 Recall 一同判斷。

3.9.3 (3) Precision、Recall、mAP 是否趨於穩定？

除了 Loss 外，更重要的是觀察模型效能指標。

若

$$Precision_{t+1} \approx Precision_t$$

$$Recall_{t+1} \approx Recall_t$$

$$mAP_{t+1} \approx mAP_t$$

表示模型性能已不再有明顯提升。

本研究中可以觀察到：

- Precision 約穩定於 0.84
- Recall 約穩定於 0.75
- mAP50 約穩定於 0.84
- mAP50-95 約穩定於 0.52

皆呈現平台（Plateau）現象，代表模型已學習完成主要特徵。

3.9.4 (4) Validation Loss 是否反彈？

最後需確認模型是否發生 Overfitting。

若出現

$$Train\ Loss \downarrow$$

但

$$Validation\ Loss \uparrow$$

代表模型開始只記住訓練資料，泛化能力下降。

本研究之 Validation Loss 並未於後期明顯上升，因此未觀察到嚴重過擬合現象。

Table 2: 模型收斂判斷依據

判斷項目	是否符合
Training Loss 持續下降	✓
Validation Loss 持續下降	✓
Loss 最後趨於水平	✓
Precision 趨於穩定	✓
Recall 趨於穩定	✓
mAP 趨於穩定	✓
Validation Loss 未反彈	✓

4 圖三：混淆矩陣分析




Figure 3: 物件偵測混淆矩陣

4.1 混淆矩陣怎麼看？

若此圖為 Ultralytics YOLO 常見輸出，通常可視為：

y 軸 = Predicted Class 預測類別

x 軸 = True Class 真實類別

因此矩陣中的元素 C_{ij} 可定義為：

$$C_{ij} = \#\{\text{true class} = j, \text{predicted class} = i\}$$

也就是「真實類別是第 j 類，但模型預測成第 i 類」的數量。

對角線與非對角線

混淆矩陣中，對角線 C_{cc} 代表類別 c 被正確分類的數量。非對角線 C_{ij} ， $i \neq j$ ，代表模型把真實類別 j 誤判成類別 i 。

4.2 類別縮寫

Table 3: 混淆矩陣類別縮寫說明

縮寫	意義
pwh	people with helmet，戴安全帽的人
pwv	people with vest，穿背心的人
pnh	people no helmet，未戴安全帽的人
pnv	people no vest，未穿背心的人
police	警察或相關人員
pwv1	people with vest new，新版或另一種背心類別
background	背景或未匹配物件

類別命名建議

圖一的類別名稱是 helmet、vest、no-helmet、no-vest、worker、head；圖三則是 pwh、pwv、pnh、pnv、police、pwv1。若這些圖要放在同一份報告或論文中，建議統一命名，否則讀者會不確定它們是否來自同一個資料集或同一次訓練。

4.3 TP、FP、FN 的矩陣公式

對於某一類別 c ：

$$TP_c = C_{cc}$$

$$FP_c = \sum_{j \neq c} C_{cj}$$

$$FN_c = \sum_{i \neq c} C_{ic}$$

因此：

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c} = \frac{C_{cc}}{\sum_j C_{cj}}$$

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c} = \frac{C_{cc}}{\sum_i C_{ic}}$$

直觀來說：

- Precision 看的是「模型預測成某類的結果中，有多少是真的」。因此用該類別的**列**去算。
- Recall 看的是「真實屬於某類的物件中，有多少被抓到」。因此用該類別的**欄**去算。

4.4 以 pwh 為例：Precision 怎麼算？

從混淆矩陣可讀出，模型預測為 pwh 的數量包含：

$$2629 + 3 + 54 + 1 + 0 + 0 + 387 = 3074$$

其中真正是 pwh 且預測為 pwh 的數量為：

$$TP_{pwh} = 2629$$

因此 pwh 的 precision 為：

$$\text{Precision}_{pwh} = \frac{2629}{3074} \approx 0.855$$

也就是：

$$\text{Precision}_{pwh} \approx 85.5\%$$

這代表模型只要預測為 pwh，大約 85.5% 是正確的。

4.5 以 pwh 為例：Recall 怎麼算？

pwh 的 recall 要看真實 pwh 這一欄中有多少被正確抓到。由圖中估算，真實 pwh 被分到各預測類別的數量包含：

$$2629 + 31 + 514 \approx 3174$$

其中正確抓到的是：

$$TP_{pwh} = 2629$$

因此：

$$\text{Recall}_{pwh} = \frac{2629}{3174} \approx 0.828$$

也就是：

$$\text{Recall}_{pwh} \approx 82.8\%$$

這代表真實 pwh 中，大約 82.8% 被模型成功偵測並分類正確。

4.6 各類別 Precision 與 Recall 估算

以下數值根據圖三的混淆矩陣估算，實際值可能會因矩陣方向、confidence threshold、IoU threshold 不同而略有差異。

Table 4: 由混淆矩陣估算的各類別 Precision 與 Recall

類別	TP	Precision 約略值	Recall 約略值
pwh	2629	85.5%	82.8%
pwv	1762	65.9%	82.4%
pnh	884	83.7%	76.3%
pnv	761	73.4%	71.1%
police	287	88.0%	58.7%
pwv1	699	80.4%	55.9%

4.7 背景列與背景欄的意義

在 YOLO 混淆矩陣中，background 通常代表沒有成功匹配到的物件或多出來的預測。

- **background row**：真實有物件，但模型預測為背景，通常可視為漏檢，False Negative。
- **background column**：模型預測出物件，但真實標註中沒有對應物件，通常可視為誤檢，False Positive。

圖中 background row 的數量約為：

$$514 + 329 + 221 + 220 + 129 + 186 = 1599$$

這代表約有 1599 個真實物件被模型漏掉或未正確匹配。

background column 的數量約為：

$$387 + 445 + 140 + 215 + 35 + 133 = 1355$$

這代表約有 1355 個預測框可能是誤檢或沒有對應到真實標註。

專業術語：False Positive 與 False Negative

False Positive，FP，代表模型預測有物件，但實際上沒有對應的真實標註，也就是誤檢。

False Negative，FN，代表真實有物件，但模型沒有成功偵測到，也就是漏檢。

4.8 混淆矩陣的主要問題

從圖三可以看出幾個重要現象：

1. **pwh 表現相對穩定**：pwh 的 precision 與 recall 都在 80% 以上。
2. **pwv precision 偏低**：pwv 的 recall 高，但 precision 約 65.9%，表示模型常把其他類別誤判成 pwv。
3. **police recall 偏低**：police precision 高，但 recall 約 58.7%，代表模型只要判成 police 多半是對的，但很多 police 沒有被抓到。
4. **pwv1 recall 偏低**：pwv1 recall 約 55.9%，代表新版背心或相似背心類別容易被漏檢或被判成其他背心類別。
5. **background 數量偏高**：表示模型仍存在一定程度的漏檢與誤檢。

圖三結論

混淆矩陣顯示模型不是完全不能辨識，而是主要錯在相似類別混淆與 background 錯誤。特別是 pwv 與 pwv1、pwh 與 pnh、pnv 與 pwv 類別之間，需要檢查標註一致性與類別定義是否過於接近。

5 三張圖合併後的整體結論

綜合圖一、圖二、圖三，可以得到以下判斷：

1. **資料面**：資料量充足，但存在類別不平衡，最大類別與最小類別約差 3.41 倍。
2. **物件大小面**：許多 bounding box 偏小，因此小物件偵測是主要挑戰。
3. **訓練面**：loss 穩定下降，precision、recall、mAP 上升後趨於平穩，模型基本收斂。
4. **泛化面**：validation loss 沒有明顯反彈，因此目前沒有看到嚴重過擬合。
5. **偵測能力**：mAP50 約 0.84，代表一般偵測能力不錯。
6. **定位能力**：mAP50-95 約 0.52，代表在嚴格定位標準下仍有改善空間。
7. **錯誤型態**：主要問題是相似類別混淆、漏檢與小物件定位不夠精準。

總結一句話

此模型已經達到基本收斂與可用的偵測能力，但若要用於工安場域，應優先改善 recall、小物件偵測、相似背心類別混淆，以及未戴安全帽或未穿背心等安全關鍵類別的漏檢問題。

6 改善方向

6.1 資料與標註改善

- 增加少數類別資料，例如 worker、no-helmet、police、pwv1。
- 檢查相似類別標註是否一致，例如 pwv 與 pwv1 是否真的需要分開。
- 增加遠距離、小物件、遮擋、不同光照與不同角度樣本。
- 若工安應用重點是違規偵測，應特別增加 no-helmet 與 no-vest 的樣本。

6.2 模型與訓練改善

- 提高輸入解析度，例如從 640 提高到 960 或 1280，以改善小物件偵測。
- 使用較大的 YOLO 模型，提升特徵表示能力。
- 針對少數類別做 oversampling 或 class-aware augmentation。
- 調整 confidence threshold：若更怕漏檢，可以降低 threshold 提高 recall。
- 調整 NMS threshold：避免相近物件被過度刪除。

6.3 報告或論文可以這樣寫

由訓練曲線可觀察到，訓練集與驗證集 loss 皆呈現穩定下降，且驗證 loss 未在後期明顯反彈，顯示模型已基本收斂且未出現嚴重過擬合。最終 precision 約為 0.84，recall 約為 0.75，代表模型誤檢控制尚可，但仍存在一定程度的漏檢問題。mAP50 約為 0.84，顯示模型具備良好的基本偵測能力；然而 mAP50-95 約為 0.52，表示模型在嚴格定位標準下仍有改善空間。混淆矩陣進一步顯示，背心相關類別之間存在明顯混淆，且 background 相關錯誤偏多。因此，後續應優先改善小物件偵測、類別不平衡、標註一致性與安全關鍵類別的 recall。

7 常見術語整理

Table 5: 物件偵測常見術語

術語	解釋
Bounding Box	物件偵測中用來標示物體位置的矩形框。
Instance	一個被標註的物件，不等於圖片張數。
Class Imbalance	類別資料量不平均，會影響模型學習。
Box Loss	衡量預測框與真實框位置差距的損失。
Classification Loss	衡量類別預測是否正確的損失。
DFL	Distribution Focal Loss，用於提升邊界框位置回歸精度。
Precision	預測為某類的結果中，有多少是真的。
Recall	真實屬於某類的物件中，有多少被抓到。
False Positive	誤檢，模型說有，但實際沒有。
False Negative	漏檢，實際有，但模型沒抓到。
IoU	預測框與真實框的重疊比例。
AP	Precision-recall curve 下的面積。
mAP50	IoU 門檻為 0.50 時的平均 AP。
mAP50-95	IoU 從 0.50 到 0.95 多個門檻下的平均 AP。
NMS	Non-Maximum Suppression，用來移除重複預測框。
Confidence Threshold	信心分數門檻，低於門檻的預測會被濾掉。